

# 小红书内容审核助手 - 项目指南

基于 Qwen2-VL + LoRA SFT 的多模态内容审核系统

## 1. 项目概述

### 1.1 项目定位

这是一个多模态内容审核系统，能够审核小红书风格的图文内容，判断是否符合平台规范。

### 1.2 技术栈

- 模型：**Qwen2-VL-2B-Instruct
- 框架：**LLaMA-Factory
- 微调方法：**LoRA + SFT
- 硬件要求：**RTX 4060 8GB 显存

### 1.3 审核类别

结果	说明
通过 (pass)	内容符合规范
需要修改 (needs_edit)	轻微问题，修改后可发布
违规删除 (remove)	严重违规，直接删除
人工复核 (escalate)	需人工判断

## 2. 环境配置

### 2.1 创建 Conda 环境

```
bash

conda create -n llama_factory python=3.10 -y
conda activate llama_factory
```

## 2.2 安装 LLaMA-Factory

```
bash

git clone https://github.com/hiyouga/LLaMA-Factory.git
cd LLaMA-Factory
pip install -e ".[torch,metrics]" -i https://pypi.tuna.tsinghua.edu.cn/simple
```

## 2.3 安装 PyTorch (CUDA 版本)

```
bash

pip install torch==2.5.1 torchvision torchaudio --index-url https://download.pytorch.org/whl/cu121
```

---

## 3. 模型下载

```
bash

pip install modelscope -i https://pypi.tuna.tsinghua.edu.cn/simple

modelscope download --model Qwen/Qwen2-VL-2B-Instruct --local_dir models/Qwen2-VL-2B-Instruct
```

---

## 4. 数据集准备

### 4.1 数据格式

在 `data/content_review_sft.json` 中，格式如下：

```
json
```

```
[
  {
    "messages": [
      {
        "role": "system",
        "content": "你是小红书内容审核助手，负责判断用户发布的内容是否符合平台规范。..."
      },
      {
        "role": "user",
        "content": "请审核这段文案：「xxx」"
      },
      {
        "role": "assistant",
        "content": "审核结论：通过\n\n分析：..."
      }
    ]
  }
]
```

4.2 注册数据集

在 `data/dataset_info.json` 中添加：

```
json
{
  "content_review_sft": {
    "file_name": "content_review_sft.json",
    "formatting": "sharegpt",
    "columns": {
      "messages": "messages"
    }
  }
}
```

4.3 数据分布

类型	数量	示例
虚假宣传	~200	"一周瘦20斤"
私域引流	~200	"加V: xxx"

类型	数量	示例
医疗违规	~150	"祖传秘方"
诱导互动	~100	"点赞抽奖"
正常内容	~350	日常分享

5. SFT 训练

5.1 创建训练配置

创建 `train_sft.yaml`:

yaml

### ### 模型配置

`model_name_or_path`: models/Qwen2-VL-2B-Instruct

`trust_remote_code`: `true`

### ### 训练方法

`stage`: sft

`do_train`: `true`

`finetuning_type`: lora

### ### LoRA 配置

`lora_target`: all

`lora_rank`: 8

`lora_alpha`: 16

`lora_dropout`: 0.05

### ### 数据集配置

`dataset`: content\_review\_sft

`template`: qwen2\_vl

`cutoff_len`: 2048

### ### 训练参数

`output_dir`: saves/qwen2vl-content-review-sft

`logging_steps`: 10

`save_steps`: 500

`learning_rate`: 1.0e-4

`num_train_epochs`: 3.0

`per_device_train_batch_size`: 1

`gradient_accumulation_steps`: 8

`max_grad_norm`: 1.0

`warmup_ratio`: 0.1

`bfloat16`: `true`

### ### 其他

`plot_loss`: `true`

## 5.2 开始训练

```
bash
```

```
llamafactory-cli train train_sft.yaml
```

## 5.3 训练结果

指标	值
训练样本	1,020 条
训练轮次	3 epochs
最终 Loss	0.305
训练时长	~12 分钟

6. 测试模型

```
bash

llamafactory-cli chat \
  --model_name_or_path models/Qwen2-VL-2B-Instruct \
  --adapter_name_or_path saves/qwen2vl-content-review-sft \
  --template qwen2_vl \
  --finetuning_type lora
```

测试样例：

- 请审核这段文案：「分享今天做的午餐，番茄炒蛋，简单又好吃」 → 通过
- 请审核这段文案：「这款美白霜用了一周，皮肤白了三个色号！」 → 违规删除
- 请审核这段文案：「私我领取内部优惠券，比官方便宜50%」 → 违规删除

7. 导出模型

7.1 创建导出配置

创建 export\_sft.yaml：

```
yaml
```

```
model_name_or_path: models/Qwen2-VL-2B-Instruct
adapter_name_or_path: saves/qwen2vl-content-review-sft
template: qwen2_vl
finetuning_type: lora
export_dir: models/qwen2vl-content-review-sft-merged
export_size: 2
export_legacy_format: false
```

## 7.2 执行导出

```
bash

llamafactory-cli export export_sft.yaml
```

## 8. 部署 Demo

### 8.1 安装 Gradio

```
bash

pip install gradio qwen-vl-utils -i https://pypi.tuna.tsinghua.edu.cn/simple
```

### 8.2 运行 Demo

```
bash

cd src
python demo.py
```

访问 (<http://127.0.0.1:7860>)

## 9. 关键命令速查

```
bash
```

# 激活环境

```
conda activate llama_factory
```

# 训练

```
llamafactory-cli train train_sft.yaml
```

# 测试

```
llamafactory-cli chat --model_name_or_path models/Qwen2-VL-2B-Instruct --adapter_name_or_path saves/qwen2vl-content
```

# 导出

```
llamafactory-cli export export_sft.yaml
```

# 运行 Demo

```
python src/demo.py
```

## 10. 常见问题

### Q1: 显存不够怎么办?

在配置文件中添加:

yaml

```
quantization_bit: 4
```

```
per_device_train_batch_size: 1
```

```
gradient_checkpointing: true
```

### Q2: 训练 Loss 不下降?

- 检查数据格式是否正确
- 尝试调低学习率 (如  $5e-5$ )
- 增加训练轮次

### Q3: 模型输出格式不对?

- 确保训练数据格式统一
- 检查 system prompt 是否一致